

# Traitement des séries temporelles

Partie I – Modélisation et analyse de séries temporelles

Xavier Hinaut & Nathan Trouvain  
Mnemosyne - Inria/IMN/LabRI

# Sommaire

Introduction

I. Modélisation et analyse de séries temporelles

II. Apprentissage artificiel

III. Ouverture

# Introduction

# Introduction: *Timeseries in the wild*

## Nature des séries temporelles

Processus aléatoire (discret ou continu)

$$\{\dots, X_t, X_{t+1}, \dots, X_{t+n}, \dots\}$$

Observation et  
échantillonnage

$$h(X_t)$$

—  
—  
—

Séries temporelles (discret)

$$\{x_0, x_1, \dots, x_t, x_{t+1}, \dots, x_{t+m}\}$$

déf.

Un tirage (ou observation) d'un **processus aléatoire**  $\{\dots, X_{tn}, X_{t(n+1)}, \dots, X_{t(n+m)}, \dots\}$  défini par un ensemble (**discret**) de **variables aléatoires indexées dans le temps** est une **série temporelle**.

# Introduction: *Timeseries in the wild*

## Domaines d'application

Processus aléatoire (discret ou continu)

$$\{\dots, X_t, X_{t+1}, \dots, X_{t+n}, \dots\}$$

ex.

- Systèmes physiques : météo, mouvement des océans, contrôle du rythme cardiaque, rayonnements lumineux et thermiques...
- Sources anthropiques : indicateurs économiques et financiers, langage, comportement...

Observation et échantillonnage

$$h(X_t)$$
  

---

Séries temporelles (discret)

$$\{x_0, x_1, \dots, x_t, x_{t+1}, \dots, x_{t+m}\}$$

You are  
here



- Données de terrain ou d'étude : température sur un an, rythme cardiaque sur une journée, vidéos et enregistrements audios, texte...
- **Données simulées : modèles géophysiques, économétriques, du langage...**

# Introduction: *Timeseries in the wild*

## Un problème difficile

Processus aléatoire (discret ou continu)

$$\{\dots, X_t, X_{t+1}, \dots, X_{t+n}, \dots\}$$

*Souvent inconnu/continu/caché*

*ex.*

- Systèmes physiques : météo, mouvement des océans, contrôle du rythme cardiaque, rayonnements lumineux et thermiques...
- Sources anthropiques : indicateurs économiques et financiers, langage, comportement...

Observation et échantillonnage

$$h(X_t)$$
  


*Souvent avec perte*

Séries temporelles (discret)

$$\{x_0, x_1, \dots, x_t, x_{t+1}, \dots, x_{t+m}\}$$

*Souvent incomplet/sans répétition*

- Données de terrain ou d'étude : température sur un an, rythme cardiaque sur une journée, vidéos et enregistrements audios, texte...
- Données simulées : modèles géophysiques, économétriques, du langage...

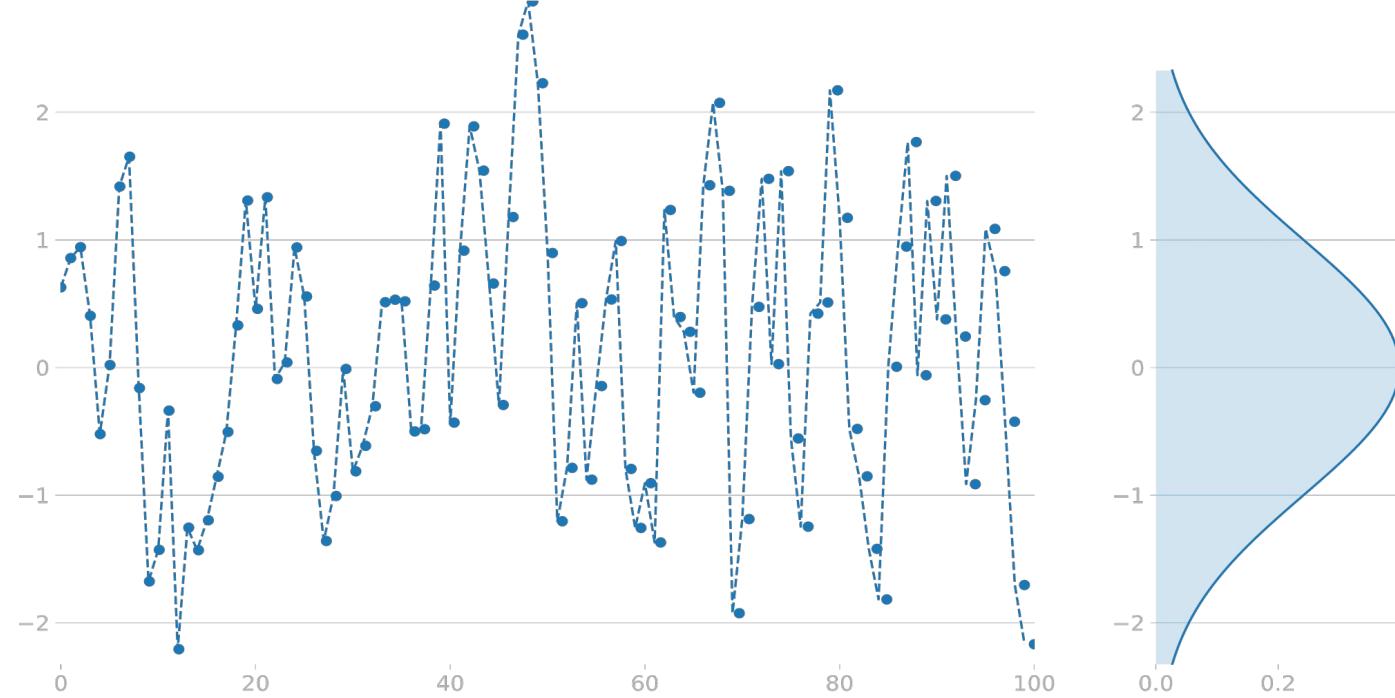
# Problématique

En quoi un processus aléatoire est différent d'une série de distributions d'événements aléatoires ?

*Est-ce que ce n'est pas  
juste du bruit gaussien,  
mais horizontalement ?*



*(spoilers: non)*



# Problématique: un exemple

*déf.*

Une série temporelle est un **agencement ordonné dans le temps** de tirages de variables aléatoires d'un processus aléatoire.

**Les tirages ne sont pas indépendants.**

*ex.*

Soit  $X_t$  une variable aléatoire représentant un pixel d'une vidéo à l'instant  $t$ :



Avec agencement:  $X_t$  dépend de  $X_{t-1, t-2, \dots, t-n}$



Sans agencement, perte d'une partie de l'information

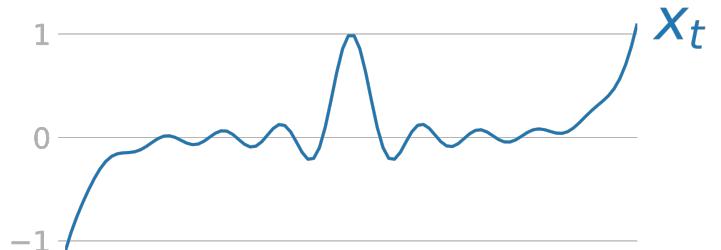
# I. Modélisation et analyse des séries temporelles

# Type de données

déf.

- Domaine continu

$$h(X_t) = x_t \in \mathbb{Z}$$



Les « vraies » **séries temporelles**, représentées dans un domaine continu (nombres réels ou complexes).

ex.

La plupart des données physiques, météos, physiologiques, financières, audio, vidéo.

déf.

- Domaine discret

$$h(X_t) = x_t \in L \leftarrow \text{Parfois appelé } \textit{lexique}$$

Appelées **séquences**. Le résultat du processus aléatoire est un symbole issu d'un ensemble discret.

ex.

Le langage, en particulier.  $L = \{\dots, <\text{le}>, <\text{en}>, <\text{particulier}>, <\text{langage}>, <.\>, <,>, \dots\}$

$x_1 \quad x_2 \quad x_3 \quad x_4 \quad x_5 \quad x_6$

# Type de données

**Il est possible de passer d'un domaine à l'autre.**

*ex.*

Attribuer un vecteur de nombres réels à un symbole: *word embedding*.

*ex.*

Attribuer un symbole à un régime d'une série temporelle: annoter un son par un symbole.

Les séries peuvent être **univariées ou multivariées**.

*ex.*

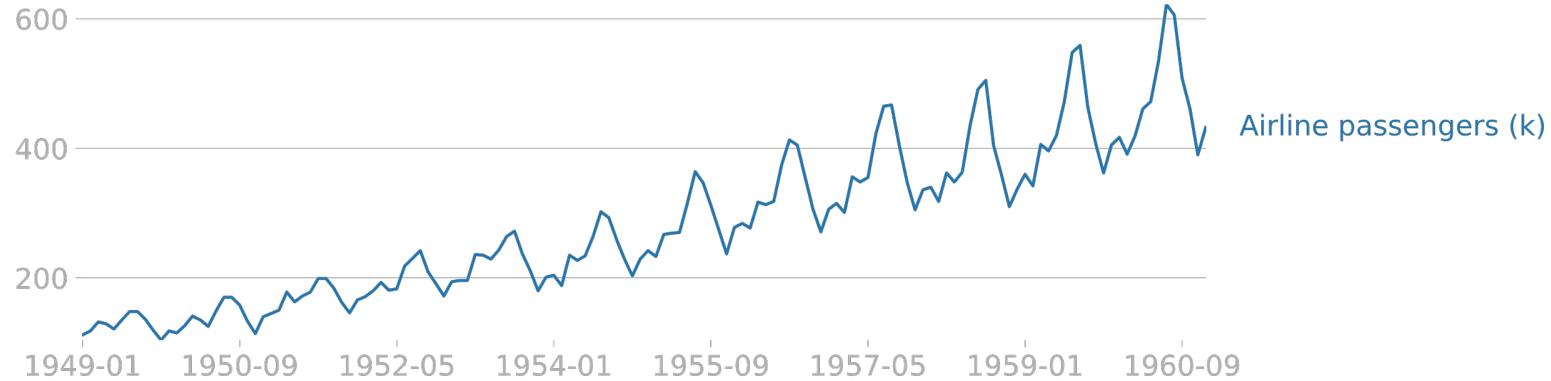
La température au cours du temps est **univariée**. La température et l'humidité au cours du temps, pris comme le résultat d'un seul phénomène, forment une série **multivariée**.

*ex.*

Les vidéos sont une forme particulière de séries multivariées (avec beaucoup de variables corrélées spatio-temporellement).

# I.1. Séries temporelles

# Décomposition



## Composantes (théoriques) d'un série temporelle

déf.

Série additive

$$X_t = c + T_t + S_t + \eta_t$$

Série multiplicative

$$X_t = c \times T_t \times S_t \times \eta_t$$

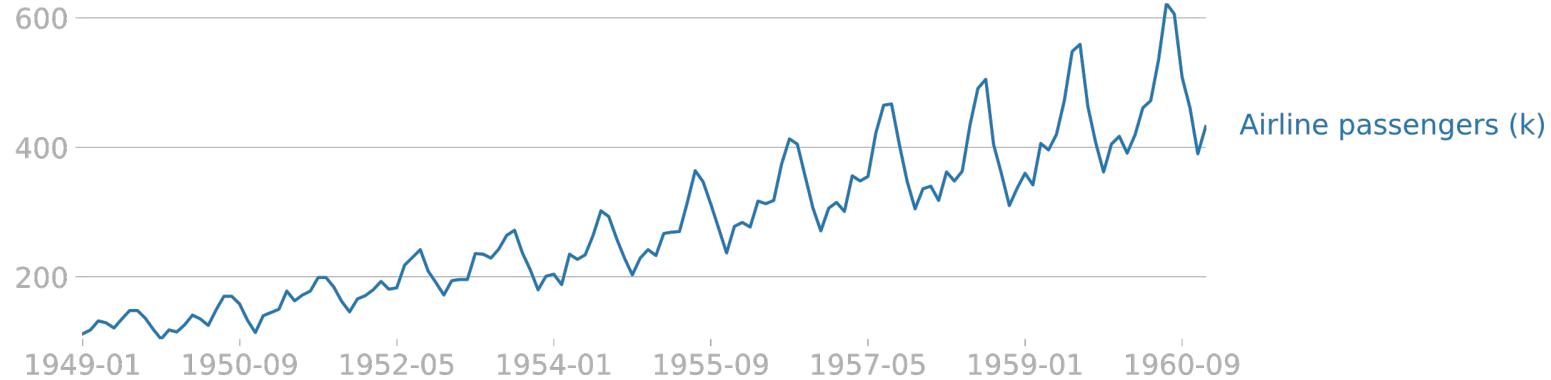
$c$  — Niveau (*level*) : moyenne de la série

$T_t$  — Tendance (*trend*) : évolution de la moyenne dans le temps

$S_t$  — Saisonnalité (*seasonality*) : cycles dans la séries

$\eta_t$  — Bruit ou résidus (*noise, residuals*) : tout ce qu'il reste. Doit être décorrélé des autres composants.

# Décomposition



## Composantes (théoriques) d'un série temporelle

déf.

Série additive

$$X_t = c + T_t + S_t + \eta_t$$

Série multiplicative

$$X_t = c \times T_t \times S_t \times \eta_t$$

$c$  — Niveau (*level*) : moyenne de la série

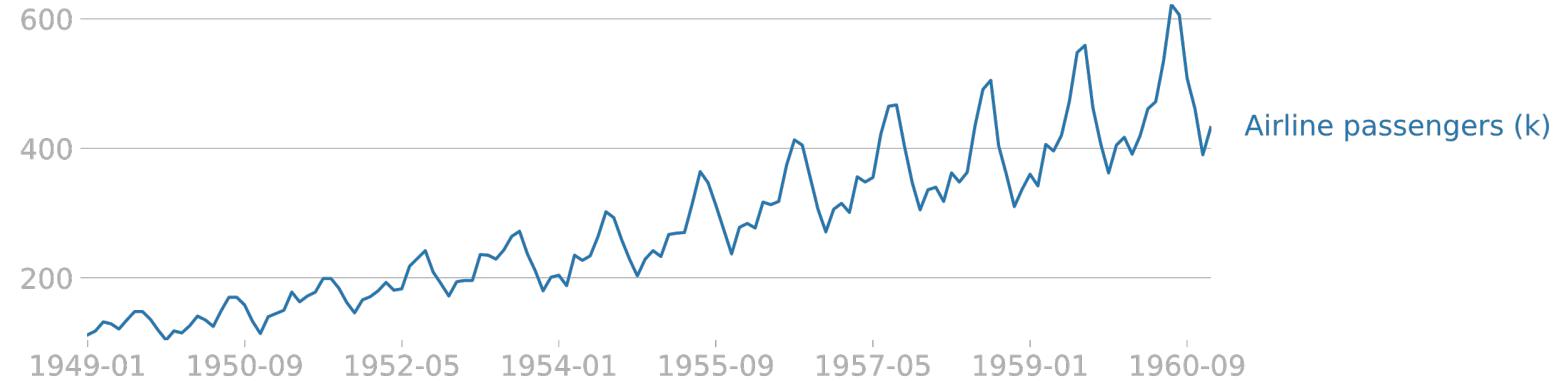
$T_t$  — Tendance (*trend*) : évolution de la moyenne dans le temps

$S_t$  — Saisonnalité (*seasonality*) : cycles dans la séries

**Composants systémiques  
Modélisables**

$\eta_t$  — Bruit ou résidus (*noise, residuals*) : tout ce qu'il reste. Doit être décorrélé des autres composants.

# Décomposition



## Composantes (théoriques) d'un série temporelle

Série **additive**

$$X_t = c + T_t + S_t + \eta_t$$

- Tendance linéaire
- Cycles à fréquence et/ou amplitude fixe

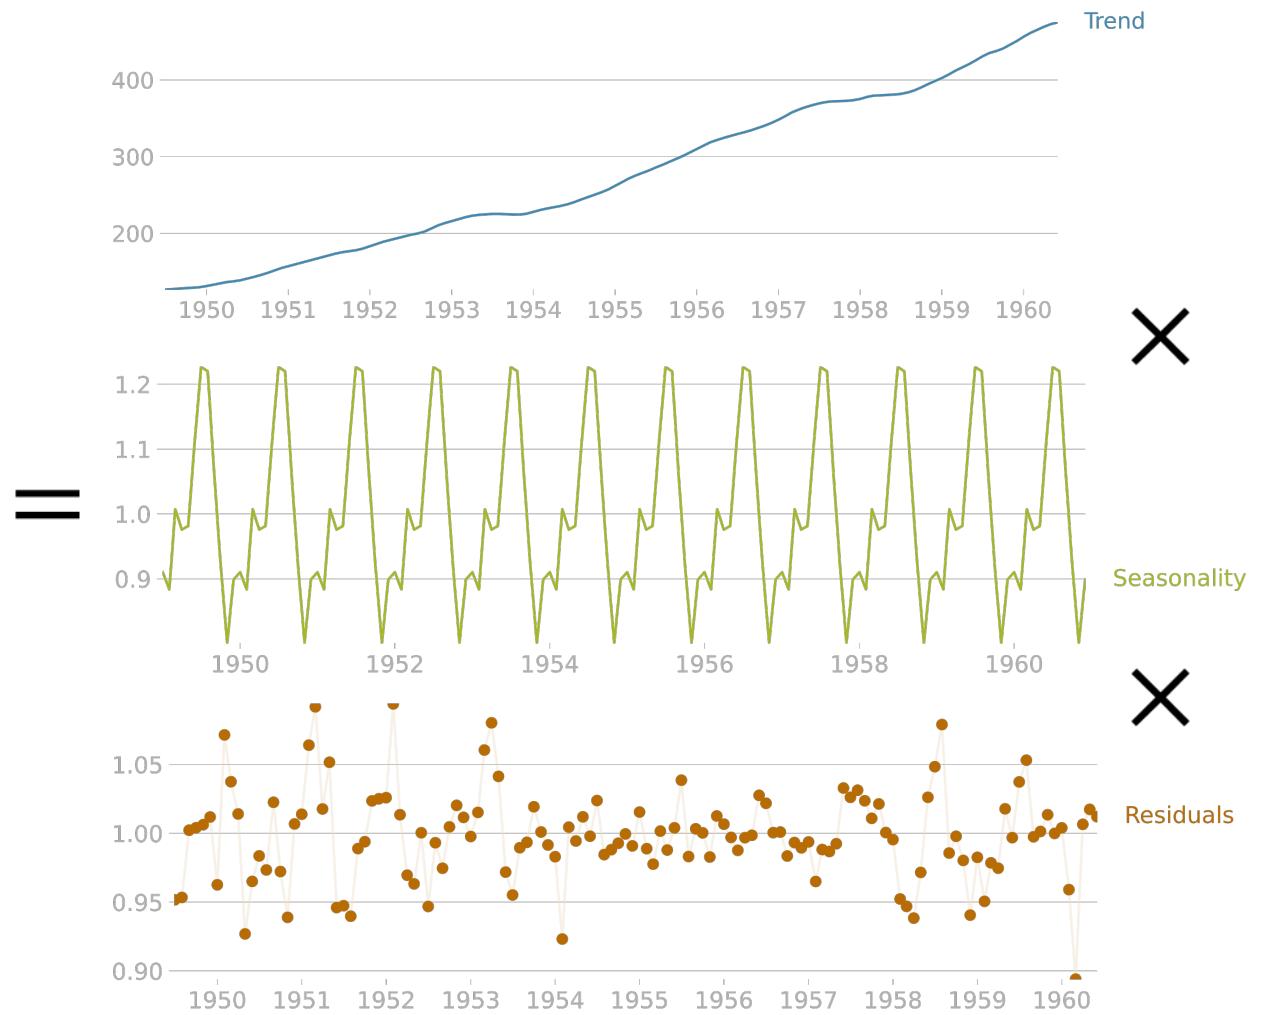
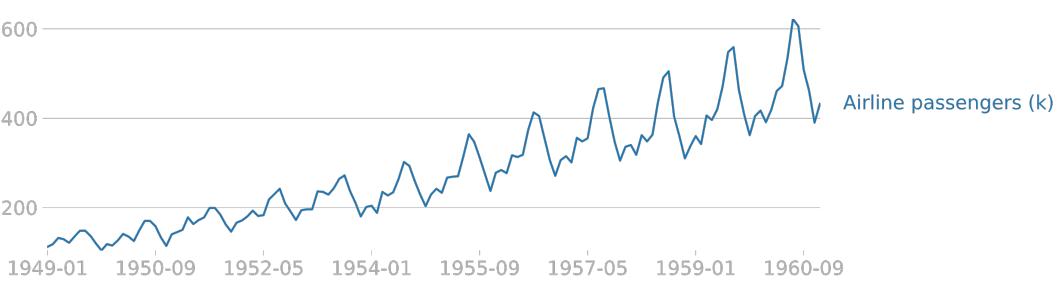
Série **multiplicative**

$$X_t = c \times T_t \times S_t \times \eta_t$$

- Tendance quadratique/exponentielle
- Cycles à fréquence et/ou amplitude variable

Dans les faits, souvent difficile à identifier clairement.

# Décomposition



Py.

```
statsmodels.tsa.seasonal.seasonal_decompose  
statsmodels.tsa.seasonal.STL
```

# Stationnarité

déf.

Une série  $X_t$  est **covariance-stationnaire** si:

$$E[X_t] = \mu \quad (\text{constant dans le temps})$$

$$\text{Var}(X_t) = \sigma^2 \quad (\text{constant dans le temps})$$

$$\text{Cov}(X_t, X_{t+\tau}) = \gamma(t) \quad (\text{constant pour tout } t)$$

Autrement dit, une série stationnaire:

- n'a pas de tendance;
- varie autour de la moyenne avec une amplitude constante;
- montre des fluctuations aléatoires à court terme similaires.

# Théorème de représentation de Wold

Th.

Tout série covariance-stationnaire  $X_t$  de moyenne  $\mu = \mathbf{0}$  peut s'écrire sous la forme:

$$X_t = V_t + S_t$$

- $V_t$  est un processus linéaire déterministe, de la forme:  $V_t = \alpha_1 V_{t-1} + \dots + \alpha_p V_{t-p} = \sum_{i=1}^{p-1} \alpha_i V_{t-i}$
- $S_t$  est un processus à moyenne mouvante infinie:  $S_t = \sum_{i=1}^{\infty} \phi_i \eta_{t-i} + \eta_t$  ( $\eta_t \sim WN(\mu, \sigma^2)$ )

Autrement dit, on admettra que toute série stationnaire de moyenne nulle admet une représentation de type ARMA (*Auto-Regressive – Moving Average*).

# Processus autorégressifs (AR( $p$ ))

déf.

- $$X_t = \alpha_0 + \alpha_1 X_{t-1} + \alpha_2 X_{t-2} + \dots + \alpha_p X_{t-p} + \eta_t$$

$$= \alpha_0 + \eta_t + \sum_{i=1}^p \alpha_i X_{t-i}$$

- La série ne dépend que de **ses valeurs passées et d'un bruit blanc  $\eta_t$** .
- Les  $\{\alpha_i\}$  sont les paramètres du modèle. Ils peuvent être estimés par simple **régression linéaire** entre  $X_t$  et  $[X_{t-1}, X_{t-2}, \dots, X_{t-p}]$ .
- Le modèle admet un **hyperparamètre  $p$ , appelé *lag***, qui détermine le **nombre de sauts dans le passé**  $X_{t-1}, X_{t-2}, \dots, X_{t-p}$  nécessaires pour **prédir la valeur actuelle  $X_t$** .

# Processus à moyenne mouvante (MA( $q$ ))

déf.

- $$X_t = \phi_0 + \phi_1 \eta_{t-1} + \phi_2 \eta_{t-2} + \dots + \phi_p \eta_{t-q} + \eta_t$$

$$= \phi_0 + \eta_t + \sum_{i=1}^q \phi_i \eta_{t-i}$$

- La série ne dépend que de **ses résidus (ou innovations) passées et courantes  $\eta_t$ .**
- Les  $\{\phi_i\}$  sont les paramètres du modèle. Estimation complexe, car  $\eta_t$  n'est pas directement accessible (algorithmes d'innovations, **Expectation Maximization (EM)**).
- Le modèle admet un **hyperparamètre q**, appelé **ordre**, qui détermine **le nombre d'innovations passées  $\eta_{t-1}, \eta_{t-2}, \dots, \eta_{t-q}$  nécessaires pour prédire la valeur actuelle  $X_t$ .**

**NB : ne pas confondre avec une moyenne glissante !**

# Identifier $p$ et $q$

## Fonction d'autocorrélation (ACF)

Dans le cas d'un processus stationnaire (condition nécessaire) de moyenne  $\mu$  et de variance  $\sigma^2$ :

$$R_X(\tau) = \frac{1}{\sigma^2} \mathbb{E}[X_t - \mu, X_{t+\tau} - \mu] = \frac{1}{\sigma^2} \sum_i^n (X_i - \mu)(X_{i-\tau} - \mu)$$

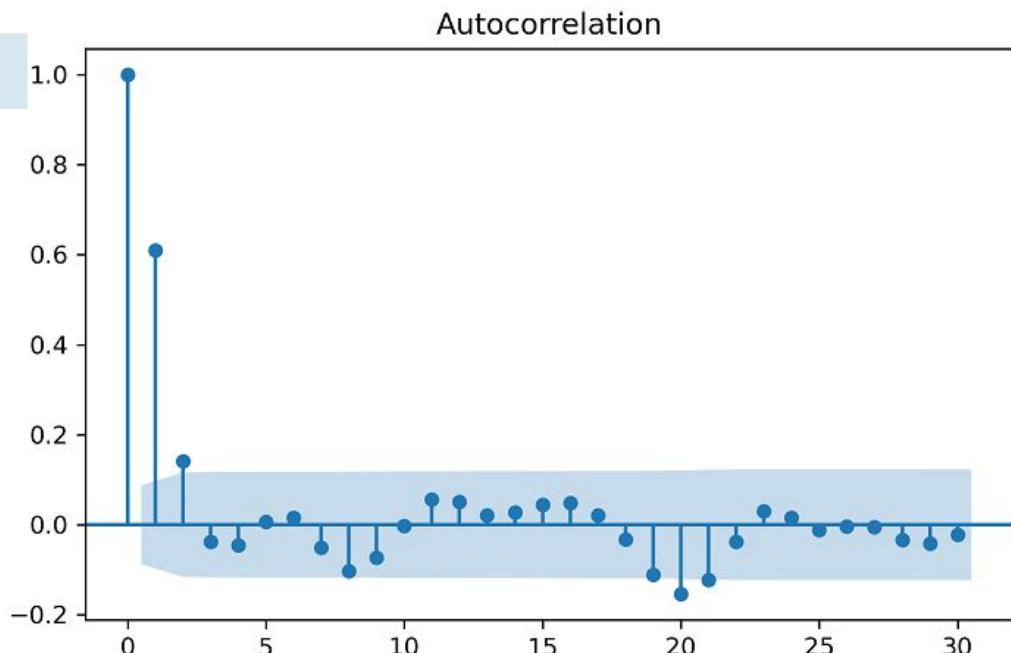
déf.

$R_X(\tau)$  est la corrélation entre  $X_t$  et lui-même décalé de  $\tau$  dans le temps,  $X_{t-\tau}$ . Si  $X_{t-\tau}$  est corrélé à  $X_t$  (valeur proche de 1 ou de -1), alors:

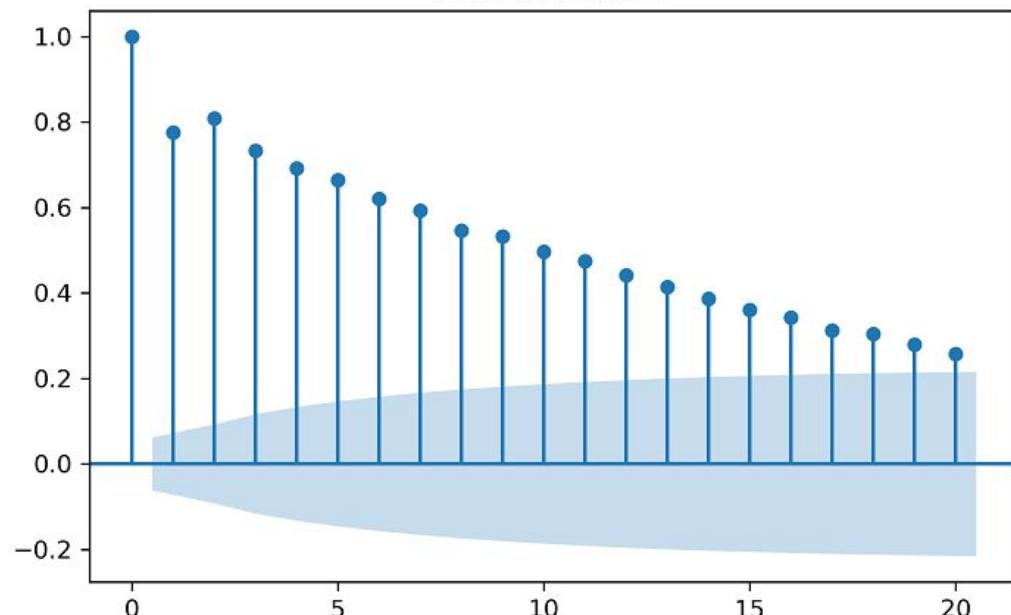
- Pour un AR:  $X_{t-\tau}$  explique  $X_t \rightarrow p \geq \tau$
- Pour un MA: si  $R_X(\tau + 1), \dots, R_X(\tau + n)$  sont proches de 0,  $q = \tau$ .

# Identifier $p$ et $q$

ex.



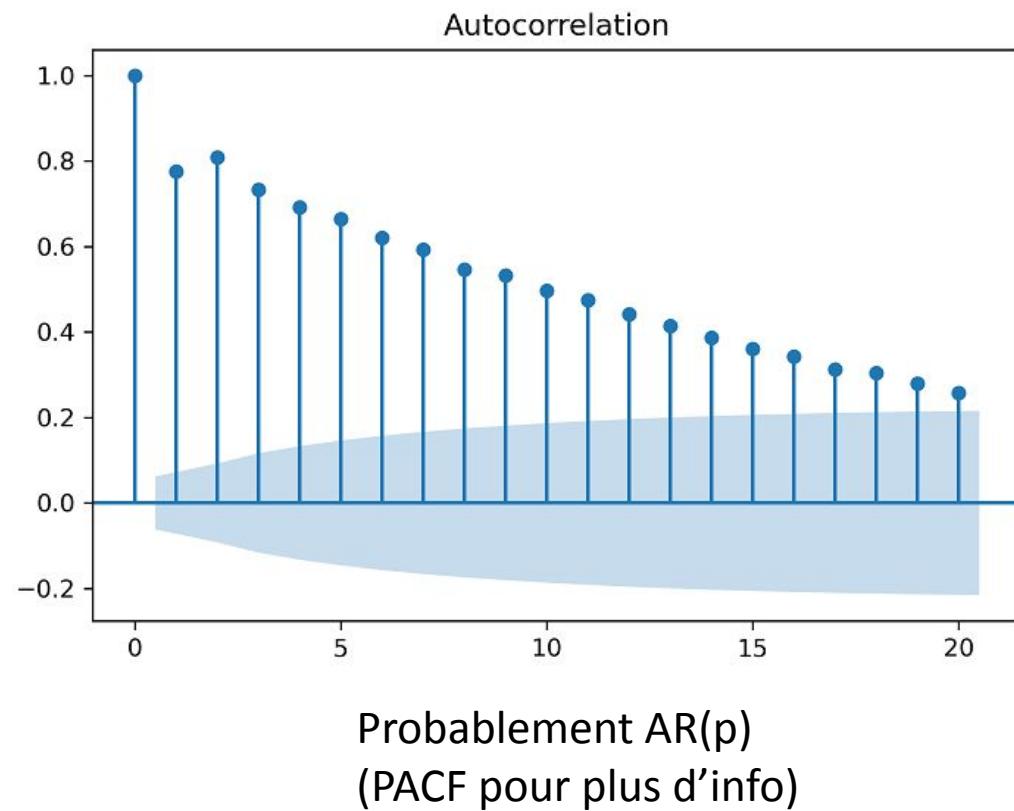
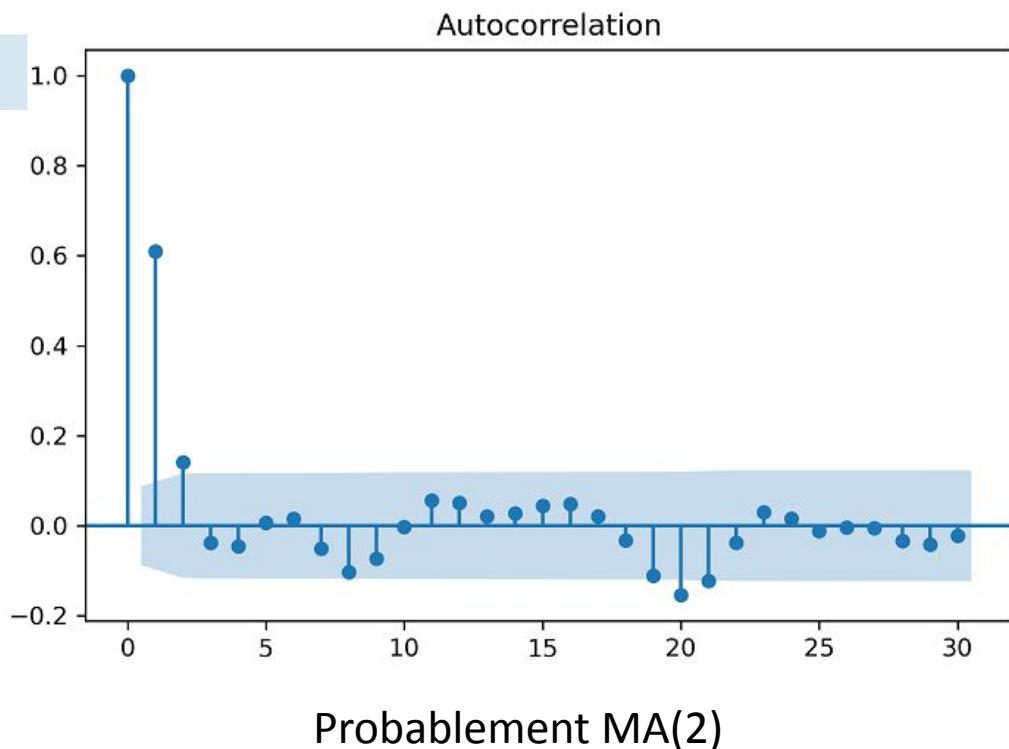
Autocorrelation



Py. `statsmodels.graphics.tsaplots.plot_acf`

# Identifier $p$ et $q$

ex.



# Identifier $p$ et $q$

## Fonction d'autocorrélation partielle (PACF)

def.

Toujours dans le cas d'un processus stationnaire,  $\phi_X(\tau)$  permet d'évaluer la corrélation entre  $X_t$  et  $X_{t+\tau}$  et seulement  $X_{t+\tau}$ .

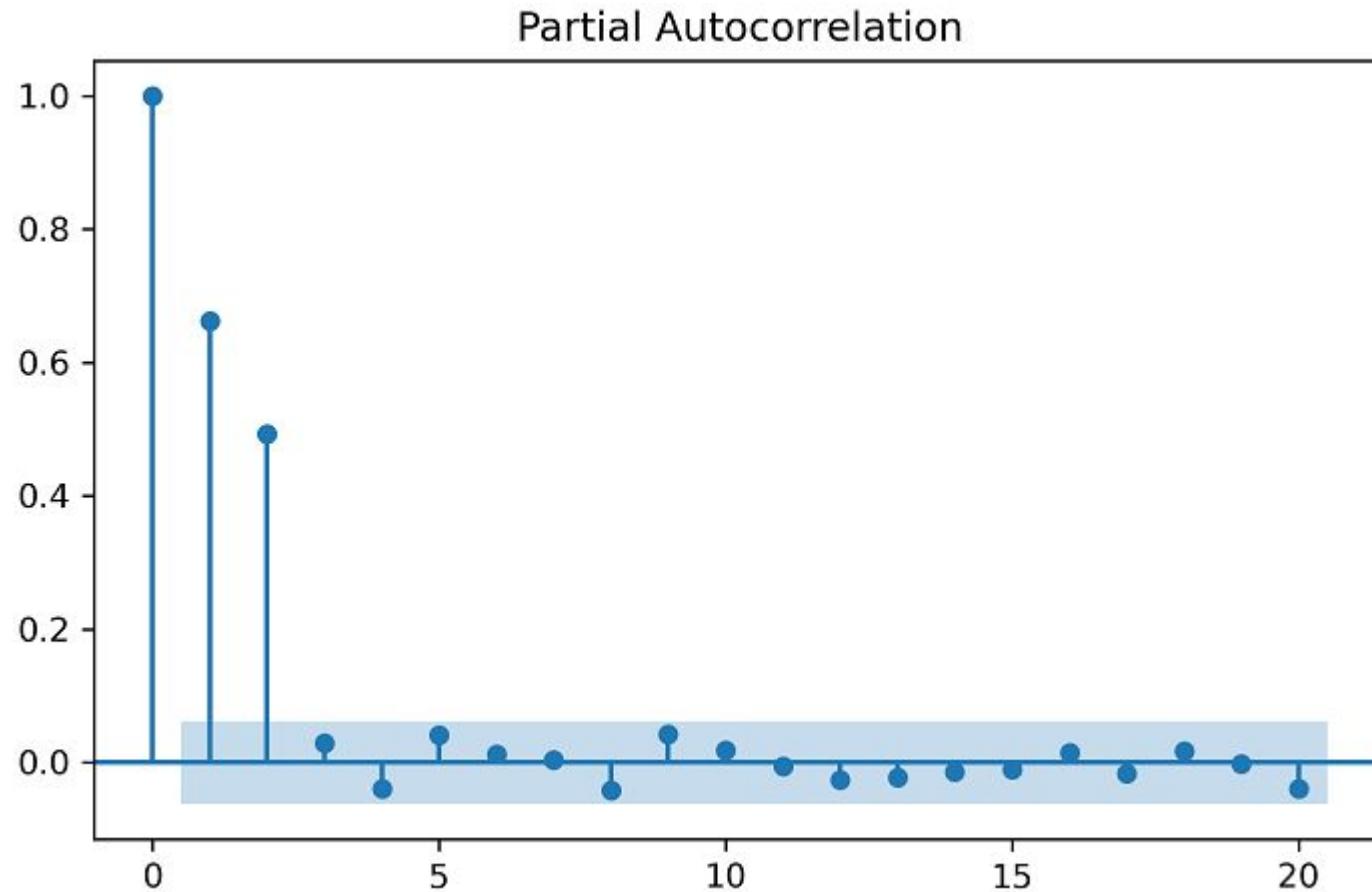
Similaire à l'ACF, mais enlevant les effets des valeurs entre  $X_t$  et  $X_{t+\tau}$ , permettant de clairement identifier les dépendances.

Si  $X_{t-\tau}$  est corrélé partiellement à  $X_t$  ( $\phi_X(\tau)$  proche de 1 ou de -1), alors:

- Pour un AR: si  $\phi_X(\tau + 1), \dots, \phi_X(\tau + n)$  sont proches de 0,  $p = \tau$ .
- Pour un MA: pas de conclusion.

# Identifier $p$ et $q$

ex.

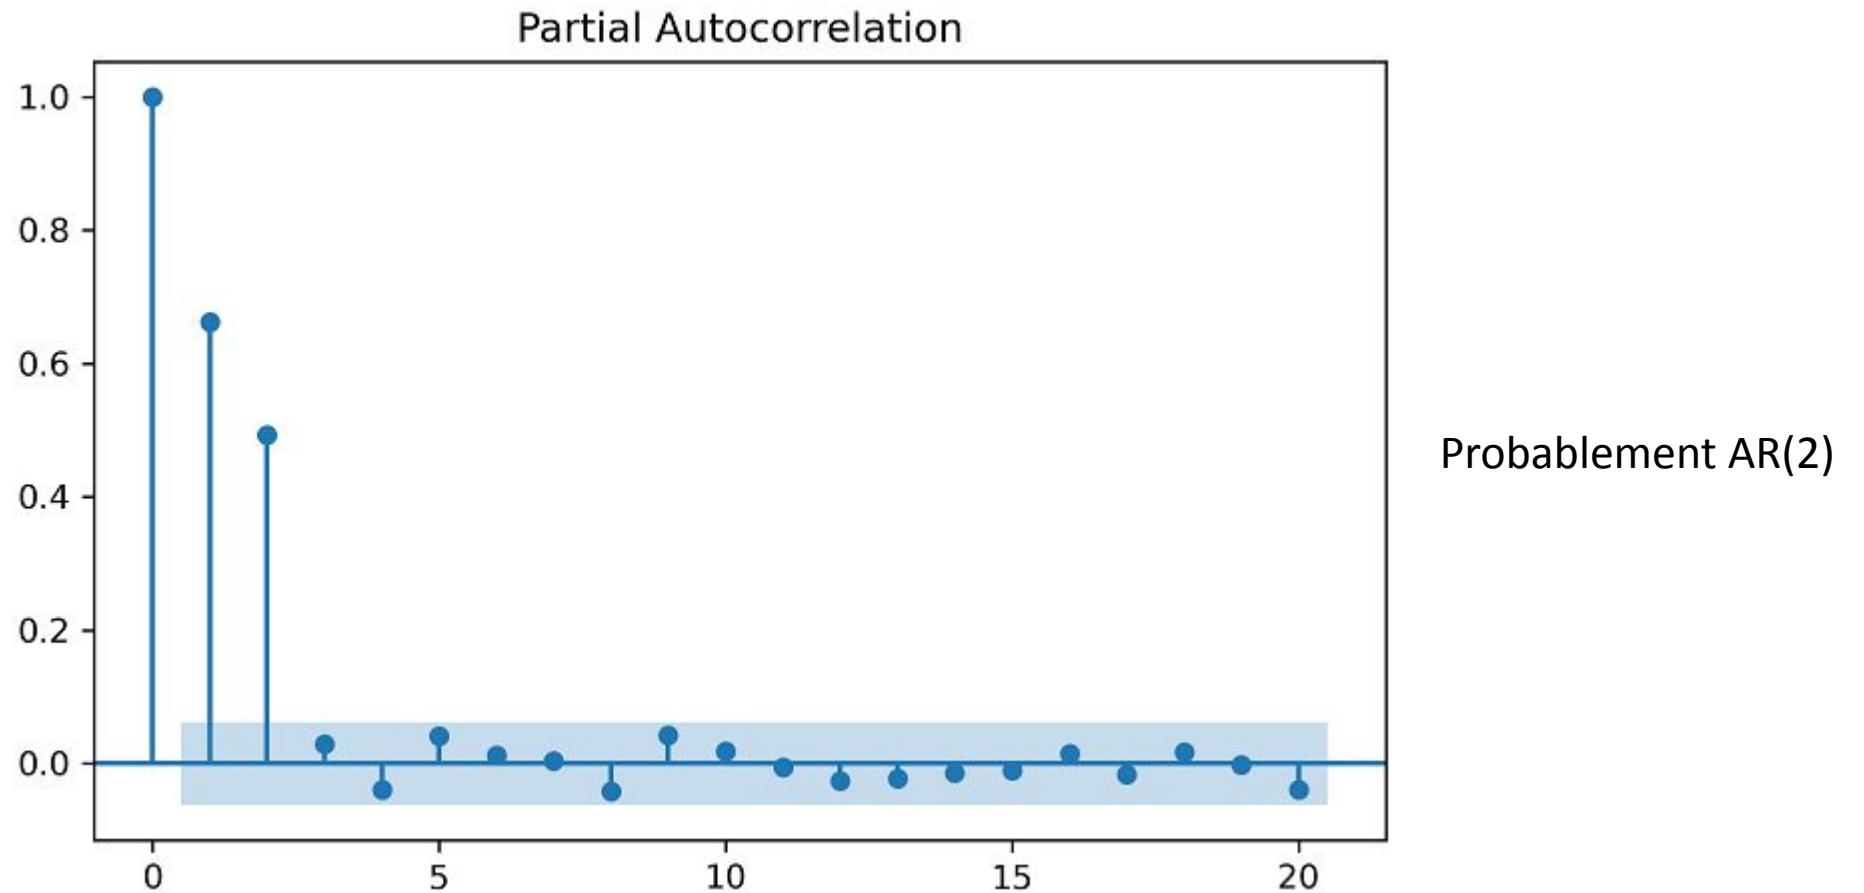


Py.

```
statsmodels.graphics.tsaplots.plot_pacf
```

# Identifier $p$ et $q$

ex.



# Cas non-stationnaires et opérateur $I^d$

Evaluer la stationnarité: **test augmenté de Dickey-Fuller ou test KPSS**

Py.

```
statsmodels.tsa.stattools.adfuller statsmodels.tsa.stattools.kpss
```

Traiter les séries non-stationnaires:

- Variance non constante, amplitude exponentielle: **essayer de prédire  $\log(X_t)$**  (multiplicatif → additif)
- Tendance, comportement non stationnaire complexe: **essayer de différencier la série.**

déf.

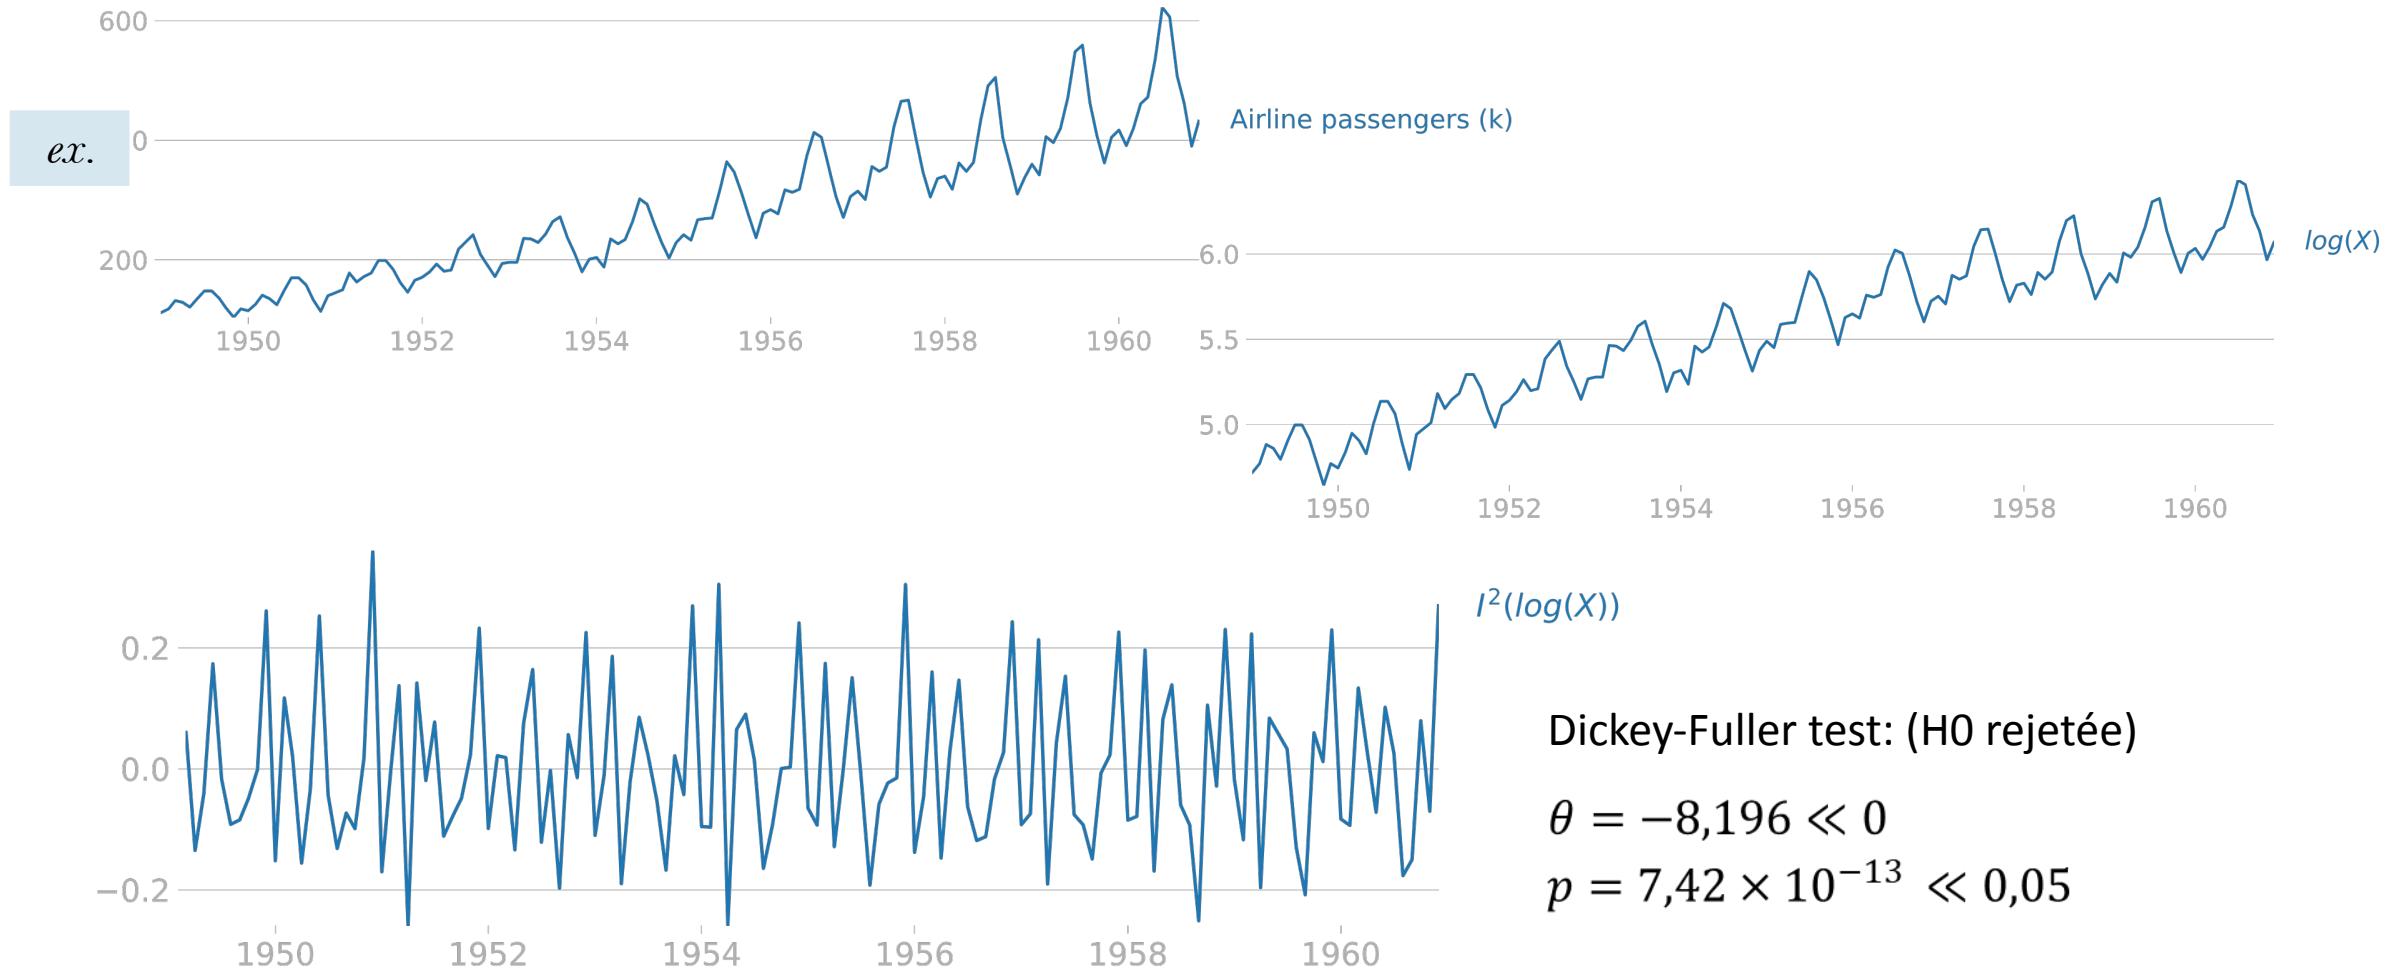
Opérateur de différenciation  $I^d$ :

$$I(X_t) = X_t - X_{t-1}$$
$$I^2(X_t) = I(I(X_t)) = X_t - 2X_{t-1} + X_{t-2}$$

$$I^d(X_t) = \sum_k^d \binom{d}{k} X_{t-k}$$

Un paramètre: son ordre  $d$ . **On doit avoir  $I^d(X_t)$  stationnaire, avec  $d$  le plus faible possible.**

# Cas non-stationnaires et opérateur $I^d$



# Processus ARIMA( $p, d, q$ )

déf.

Modèle complet,  $I^d(X_t) = AR(p) + MA(q) + \eta_t$  avec  $I^d(X_t)$  **stationnaire** et  $\eta_t \sim WN(\mu, \sigma^2)$

Correspond au cas le plus général, lorsque AR ou MA n'apparaissent pas clairement seuls lors de l'analyse, et lorsque  $X_t$  n'est pas stationnaire.

Par extension:

- un modèle AR  $\leftrightarrow$  ARIMA(0,  $d$ ,  $q$ )
- un modèle MA  $\leftrightarrow$  ARIMA( $p$ ,  $d$ , 0)
- un modèle ARMA  $\leftrightarrow$  ARIMA( $p$ , 0,  $q$ )

# Processus SARIMA( $S, P, D, Q, p, d, q$ )

déf.

• Extension de ARIMA aux séries présentant un saisonnalité:

$$I_D^d(X_t) = AR_1(p) + MA_1(q) + AR_S(P) + MA_S(Q) + \eta_t$$

$$= \sum_k^p \alpha_k X_{t-k} + \sum_k^q \phi_k \eta_{t-k} + \sum_k^P A_k X_{t-sk} + \sum_k^Q \Phi_k \eta_{t-sk} + \eta_t$$

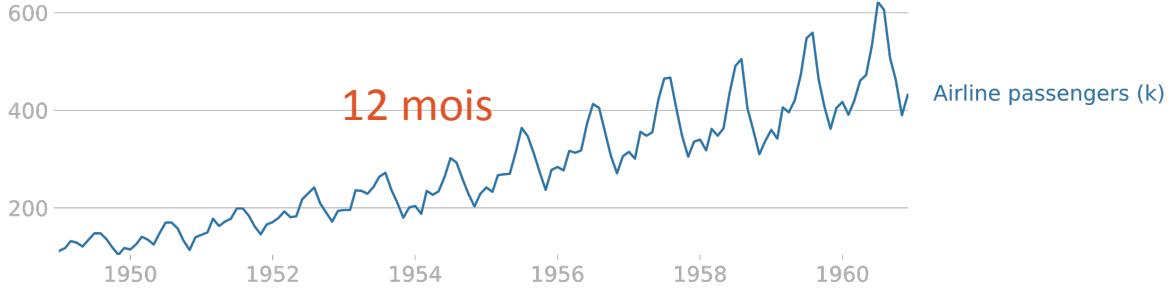
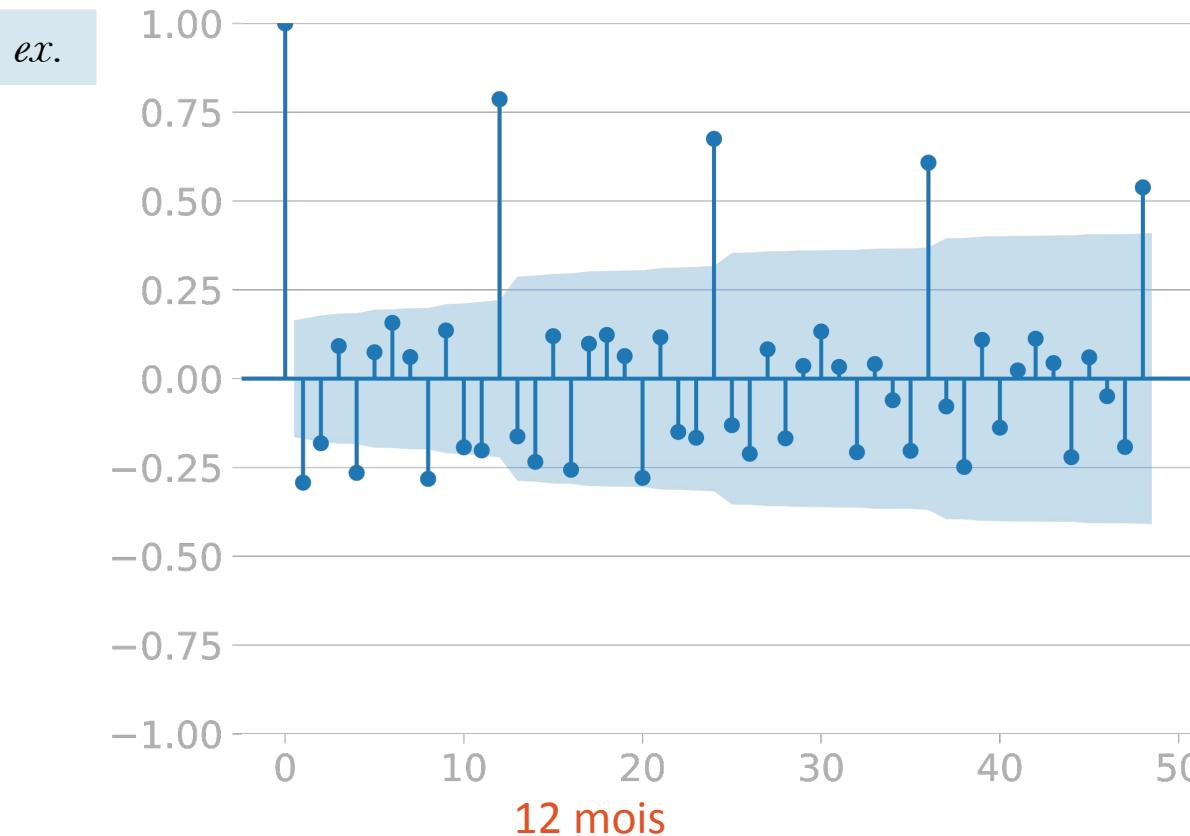
Permet de pallier aux ARIMA dans le cas de processus non stationnaires saisonniers.

Un SARIMA est la combinaison d'un ARIMA( $p, d, q$ ) liant les observations du processus à chaque pas de temps  $t$  et d'un ARIMA( $P, D, Q$ ) liant les observations à chaque pas de temps  $S \times t$ .

**$S$  est la période des saisons.**

# Processus SARIMA( $S, P, D, Q, p, d, q$ )

Autocorrelation



→ Processus AR( $P$ ), MA( $Q = 0$ ),  $S = 12$   
Voir la PACF pour déterminer  $P$

# Méthode de Box-Jenkins

déf.

## 1. Identifier:

- Saisonnalité, stationnarité, additif/multiplicatif
- Pré-traitements (**differentiation**, modèle de la tendance...)
- Sélectionner le(s) modèle(s) et **hyperparamètres** ( $p, d, q \dots$ )

## 2. Estimer

- Stratégie de **recherche des paramètres/modèles** (*cross-validation, walk-forward training, grid/random search...*)

## 3. Evaluer

- **Mesures sur les données de test/nouvelles données**
- Inférence sur un horizon fixe (***predict***)/prédictions sur un intervalle (***forecast***)

# Estimation des modèles

- Cross-validation and *walk-forward training*

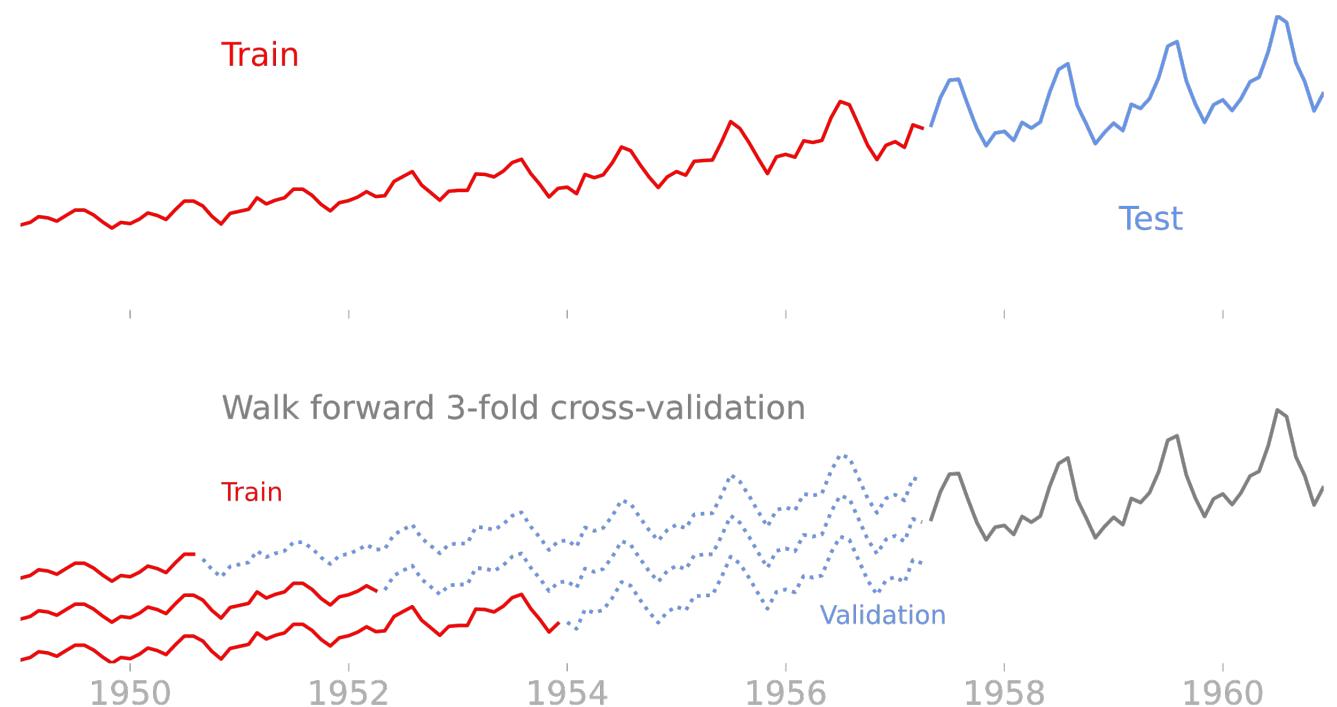
Toujours considérer une liste de paramètres  $p, d, q, P, D, Q \dots$  en cas de doute.

- Métriques

Métriques de régression (MAE, MSE...)

AIC pour la sélection des paramètres

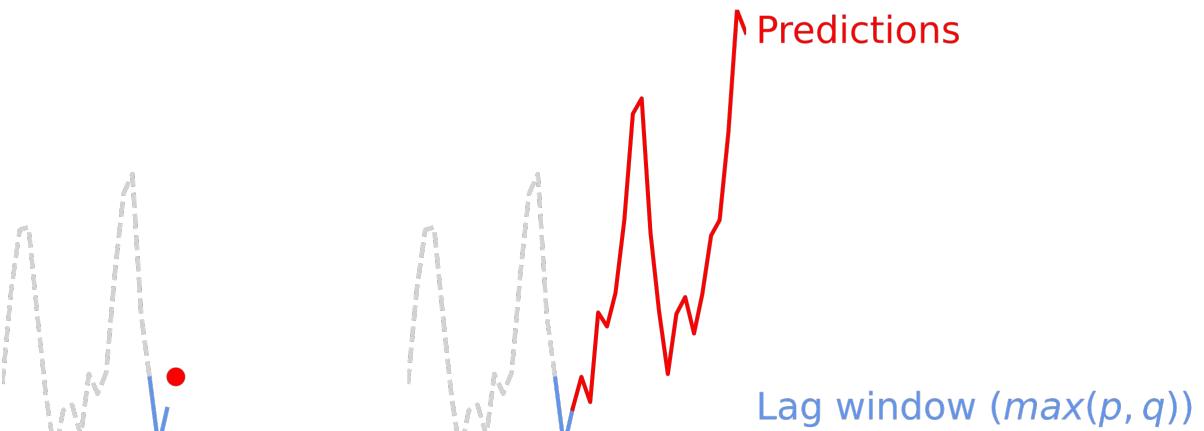
Vérifier que  $\eta \sim WN(\mu, \sigma^2)$  (Q-Q plot, tests)



# Evaluation des modèles - Inférence

- Sur les données de test

Prediction  $X_{t+1}$    Forecast  $X_{t+1} \dots X_{t+n}$



- *Warmup*

déf.

Un modèle d'ordre  $p$  a besoin d'au moins  $p$  pas de temps de données avant de commencer à prédire le pas de temps  $p + 1$ .

« Echauffer » le modèle avec des données d'entraînement avant de commencer à prédire. Si ces données ne sont pas disponibles, trouver une initialisation (aléatoire, fenêtre de  $p$  pas de temps issue de données similaires...).

# Ouverture

- Limites des modèles ARIMA:

- $p, q \rightarrow \infty$  (séries **chaotiques**);
- observations partielles (bruit important, points manquants, fonction d'observation très incomplète);
- changements de régime (stationnarité locale uniquement, cassures structurelles)...

- Autres modèles

Prophet, Theta forecaster, Exponential smoothing, ARIMAX/SARIMAX (données exogènes), modèles à changement d'état...

- Modèles multivariés (séries longitudinales ou *panel*)

VAR (Vector Auto-Regressive), NVAR (Non-linear Vector Autoregressive)...

- Réseaux de neurones

(Partie II du cours)

## I.2. Séquences

# Modèle de Markov cachés (HMM)

déf.

Soit  $X_n$  et  $Y_n$  deux processus aléatoires. En domaine discret,  $(X_n, Y_n)$  est un modèle de Markov caché si:

- $X_n$  n'est pas directement observable (états cachés);
- $P(Y_n | X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = P(Y_n | X_n = x_n), \forall n \geq 1$  (probabilité d'émission).

Autrement dit:

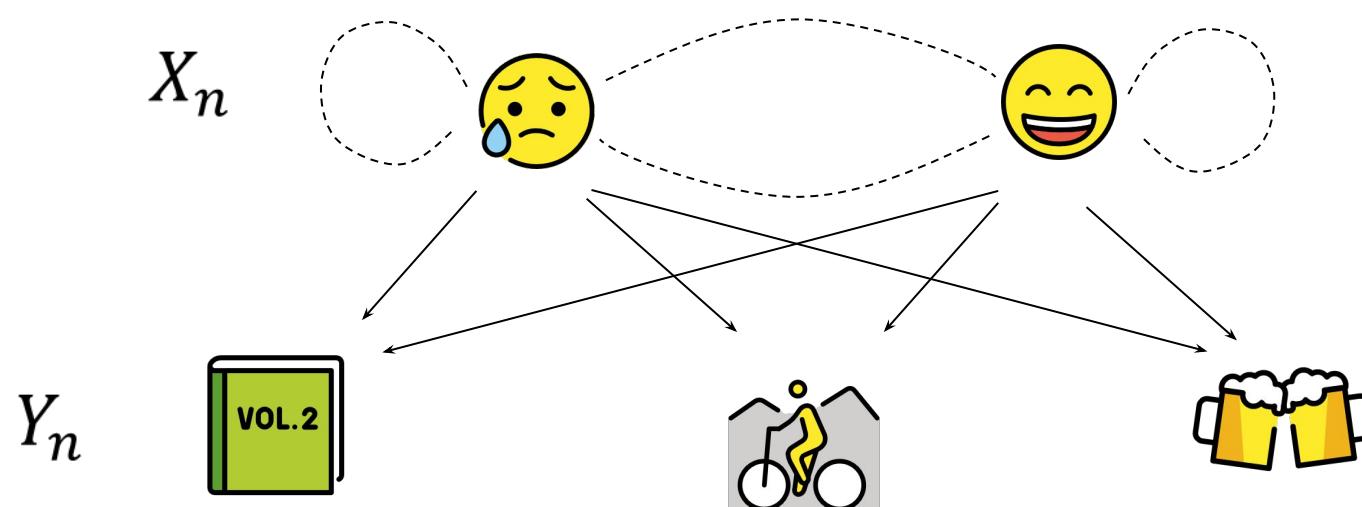
déf.

- $X_n$  correspond à une chaîne de Markov inconnue a priori (ni états, ni transitions);
- $Y_n$  ne dépend que de la valeur du dernier état  $X_n$ .

# Modèle de Markov cachés (HMM)

*ex.*

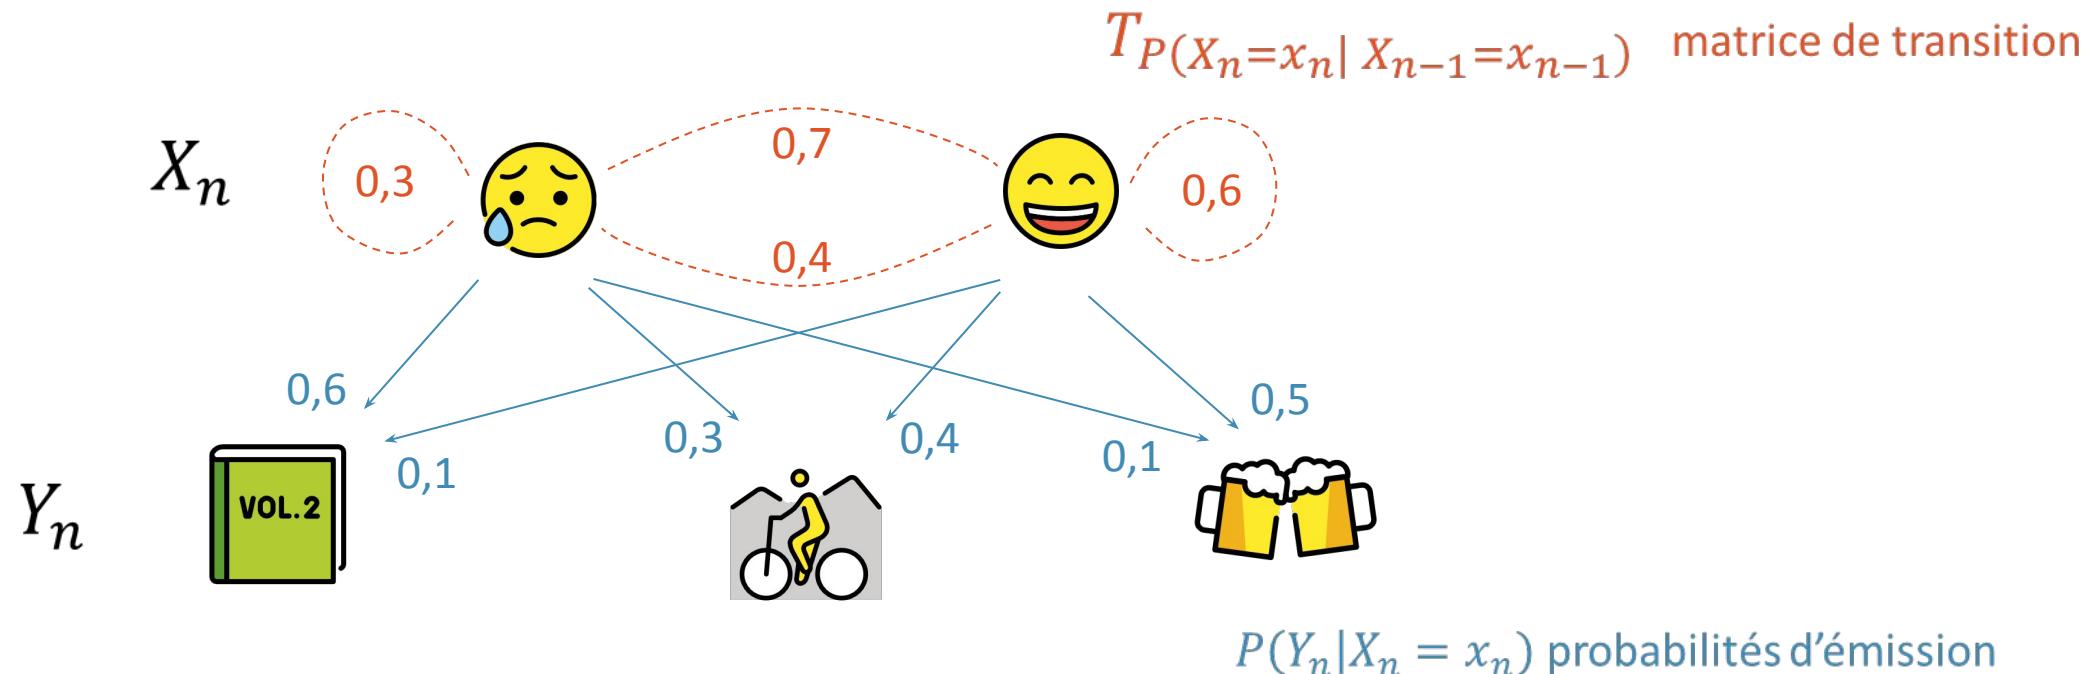
Journal d'une personne lunatique



# Modèle de Markov cachés (HMM)

ex.

Journal d'une personne lunatique



# Estimation

- Paramètres

Matrice de transition  $T_X$ , probabilités d'émission  $P(Y_n|X_n = x_n)$ , état initial  $X_0$ .

- Méthode d'estimation

A partir d'une ou plusieurs séquences d'observations  $Y_n$ :

$$Y = \{ \quad \text{VOL.2} \quad \text{bicyclist} \quad \text{bicyclist} \quad \text{VOL.2} \quad \text{beer} \quad \text{beer} \quad \text{VOL.2} \quad \text{beer} \quad \text{bicyclist} \quad \text{VOL.2} \quad \dots \}$$
A sequence of observations Y represented as a set. It contains ten elements: a book icon labeled 'VOL.2', a bicyclist icon, a bicyclist icon, a book icon labeled 'VOL.2', two beer mugs, a book icon labeled 'VOL.2', two beer mugs, a bicyclist icon, a book icon labeled 'VOL.2', and an ellipsis '...'.

**Expectation Maximization et Méthodes MCMC (Markov Chain Monte Carlo)** : méthodes d'estimation bayésiennes en grande dimension (algorithme de Baum-Welch, Gibbs sampling...)

# Tâches d'inférences

déf.

- **Forward algorithm (filtering)**: Connaissant  $Y_0, \dots, Y_n$ , quelle est la probabilité d'être dans l'état  $X_n = x_n$  à la fin?
- **Forward-Backward algorithm (smoothing)**: Connaissant  $Y_0, \dots, Y_k, \dots, Y_n$ , quelle est la probabilité d'être dans l'état  $X_k = x_k$  à  $t = k$ ?
- **Viterbi algorithm**: Connaissant  $Y_0, \dots, Y_n$ , quelle est la séquence d'états  $X_0, \dots, X_n$  la plus probable ?
- **Prédiction**: Connaissant  $X_n$ , évident grâce aux paramètres du modèle.

# Exemple : *POS tagging*

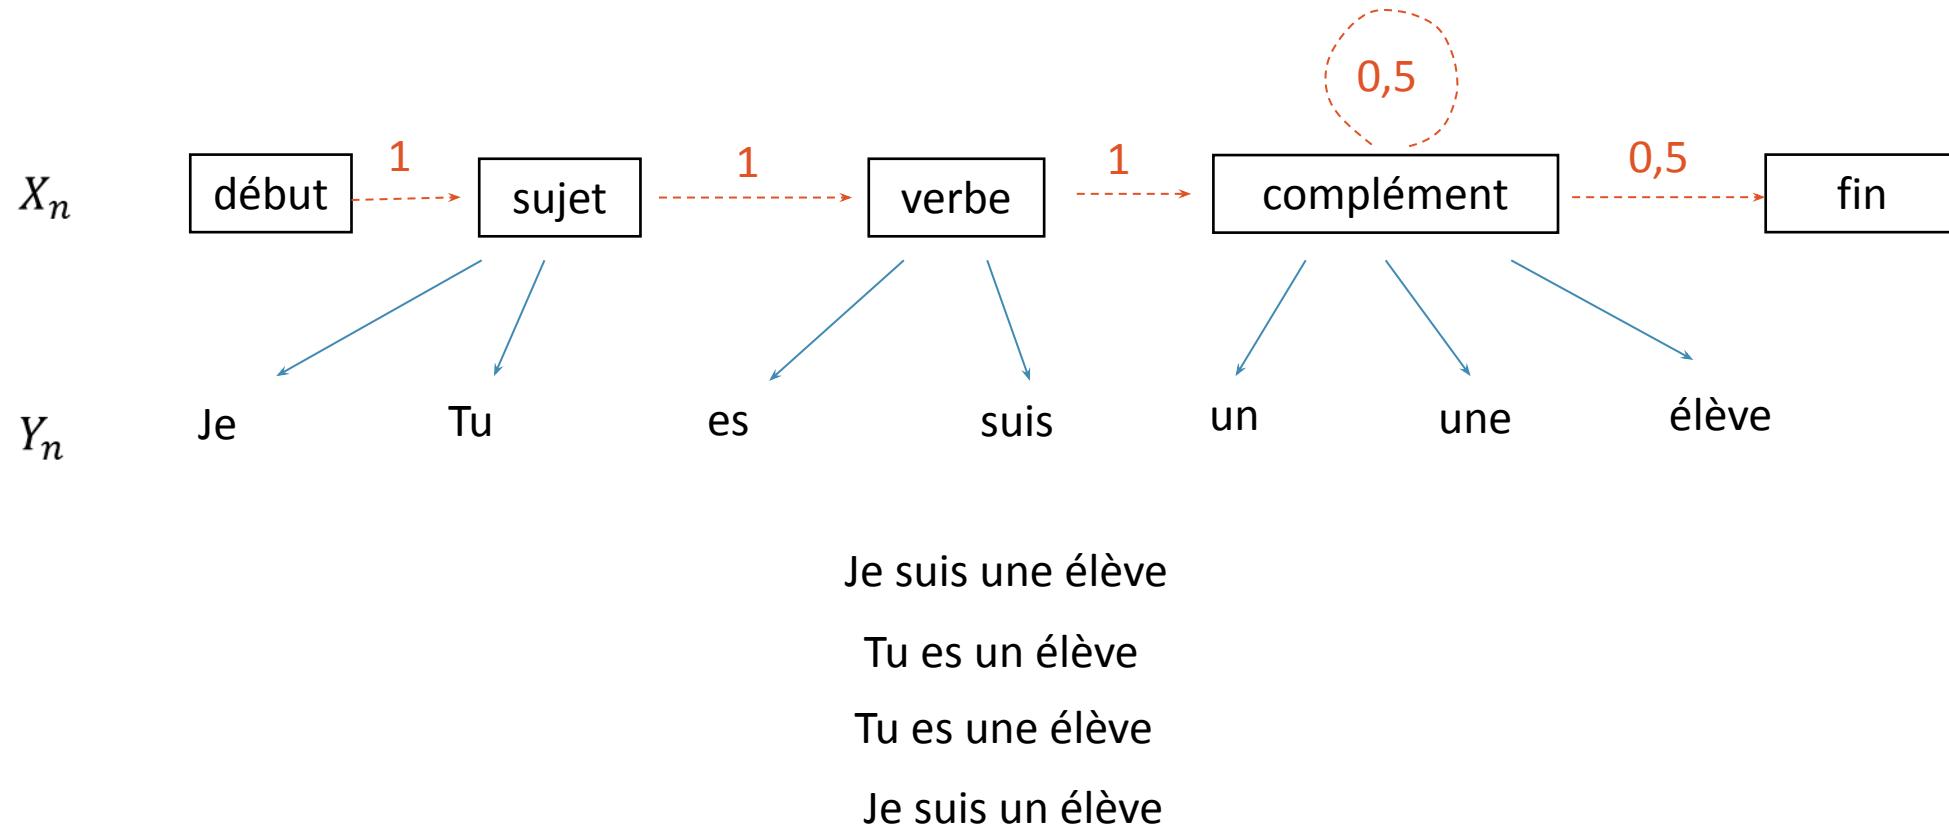
*ex.*

Soit  $X_n$  un processus décrivant l'évolution de la nature des mots (part of speech ou POS) dans une phrase.

Soit  $Y_n$  une phrase.

- Modélisation: 3 états cachés (sujet, verbe, complément); Lexique de taille 7 (« je », « tu », « es », « suis », « un », « une », « élève »).

# Exemple : *POS tagging*



# Exemple : *POS tagging*

- **Forward algorithm (filtering)**: Connaissant un bout de phrase, quelle est la nature du dernier mot ?
- **Forward-Backward algorithm (smoothing)**: Connaissant un bout de phrase, quelle est la nature d'un des mots la composant ?
- **Viterbi algorithm**: Connaissant une phrase, quelle est la nature de tous ses mots ?
- **Prédiction**: Connaissant un bout de phrase et la nature du dernier mot, quel est le mot le plus probable le suivant ?

# Ouverture

- Les HMM sont un concept permettant de modéliser de nombreux cas de figures relatifs aux séquences.
- Modélisation coûteuse en calculs.
- Vers les réseaux de neurones (modélisation implicite ou explicite de  $X_n$  de manière itérative par rétropropagation du gradient.)